Propuesta de Datos - Proyecto Centinela

Base de datos para la Fase 3 (sistema multimodal que se industrializa). Se diligencia con el formato de la compuerta de la Fase 1 (Paso 0), porque es ahí donde el proyecto fija su política de datos; las Fases 2 y 3 reutilizan estas mismas fuentes. Una página de texto (secciones 0 a 8) más tres anexos que no cuentan en la extensión: A. prueba de acoplamiento; B. evidencias del test de procedencia; C. checklist de protección de datos (uno por fuente).

0. Encabezado

Campo	Detalle
Título del proyecto	**Centinela de la Papa: alerta temprana de tizón (*early/late blight*) en cultivos de papa de pequeños productores**
Integrantes	Juan Guillermo Montaño Junca y Jair Andrés Valderrama Cano
Fecha	2026-10-30
Versión	v1

1. Problema, cliente y objetivo binario

- **Evento de riesgo y cliente:** se anticipa la presencia de tizón (gota) en la hoja de papa para un servicio de extensión agrícola / una asociación de pequeños productores de papa, que necesita decidir cuándo intervenir el cultivo.
- **Impacto:** el tizón temprano (*Alternaria solani*) y el tardío (*Phytophthora infestans*) pueden arrasar un lote en pocos días; detectarlo temprano permite focalizar el control y evitar pérdidas de cosecha y fumigaciones innecesarias.
- **Objetivo binario: hoja con tizón: sí/no.** El conjunto trae tres clases (sana, *early blight*, *late blight*); se **agrupan** las dos enfermas en «enferma» frente a «sana». Información que se pierde: el tipo de tizón (temprano vs. tardío) y la severidad. Se justifica porque la decisión del cliente en primera línea —intervenir o no ese foco— es binaria; la distinción de tipo se deja como extensión multiclase posterior.

2. Las dos modalidades del sistema completo

- **Rama de imagen:** cada imagen es una **foto RGB de una hoja de papa** tomada en campo con teléfono móvil; el instrumento es la **cámara del smartphone**. Señal que aporta: la textura, el color y el patrón de las lesiones foliares (manchas concéntricas del tizón temprano, necrosis húmeda del tardío) que distinguen una hoja enferma de una sana.
- **Rama temporal:** variables **meteorológicas diarias** —temperatura a 2 m (`T2M`), humedad relativa (`RH2M`) y precipitación (`PRECTOTCORR`)— del **reanálisis satelital/observacional de NASA POWER** para la región productora, a **frecuencia diaria**. Señal: las condiciones de humedad y temperatura que gobiernan la aparición del tizón (el tardío prospera con alta humedad y temperaturas templadas).
- **Pregunta de control, «¿La imagen contiene algo que un número no contenga?»: Sí.** La cámara y el instrumento meteorológico son dos mediciones físicamente independientes: la foto capta el estado fitosanitario real de la hoja (no derivable de la serie climática), y la serie capta las condiciones ambientales (no derivables de la foto). Son dos modalidades reales.

3. Fuentes (con enlaces y licencia)

Modalidad	Fuente (productor primario)	Enlace o DOI	Licencia y versión	Dónde se verificó la licencia	¿Datos de personas?
Imagen	Irish Potato Imagery Dataset for Early Detection of Crop Diseases (Laizer et al., Zenodo)	https://doi.org/10.5281/zenodo.8286529	**Por verificar en la ficha de Zenodo** (ver nota)	Ficha del DOI en Zenodo	No (hojas de papa)
Temporal	NASA POWER (Prediction Of Worldwide Energy Resources)	https://power.larc.nasa.gov/	Datos NASA de libre uso (con la atribución que pide la fuente)	Página de la fuente	No

> **Nota de licencia (acción obligatoria antes de aprobar):** la licencia exacta del conjunto de papa debe leerse en la ficha de Zenodo del DOI y anotarse con su nombre y versión (p. ej., CC BY 4.0). Mientras no se confirme, la condición (b) no está cerrada. NASA POWER pide incluir el agradecimiento: «The data was obtained from the NASA Langley Research Center (LaRC) POWER Project funded through the NASA Earth Science/Applied Science Program».

4. Por qué NO es un reto resuelto

- **Crudeza del dato.** El conjunto de papa son **58.709 imágenes de campo** (healthy 20.438, *early blight* 17.772, *late blight* 20.499) tomadas en condiciones reales —fondos, iluminación y ángulos variables— en fincas de pequeños productores, no imágenes de laboratorio sobre fondo blanco. Exige EDA real: desbalance entre clases, ruido de fondo, variaciones de escala e iluminación. La serie de NASA POWER llega como crudo diario que hay que limpiar, agregar y alinear temporalmente.
- **No proviene de Kaggle ni de una réplica.** El productor primario es **Zenodo** (y el artículo en *Data in Brief*, Laizer & Mduma, 2025). La descarga se hace de Zenodo, no de Kaggle. **Atención (riesgo real a documentar):** «potato leaf disease» está muy presente en Kaggle a través de **PlantVillage**, que es un corpus **distinto** (imágenes de laboratorio). El test de procedencia (Anexo B) debe demostrar, con la huella SHA-256 y la huella de crudeza, que el archivo usado es el de Zenodo y **no** coincide con PlantVillage ni con un espejo de Kaggle. Existe un espejo en Hugging Face (`Project-AgML/potato_leaf_blight`) con el **mismo origen** Zenodo: se declara, pero la descarga se hace de la fuente primaria.
- **No hay una solución pública que baste copiar** para este escenario concreto (alerta temprana multimodal foto + clima con despliegue *offline*): los trabajos publicados sobre este conjunto resuelven solo la clasificación de la imagen, no la fusión con la serie climática ni el despliegue en el borde.

5. Plan de la Fase 1, clave de alineación y prueba de acoplamiento

- **Modalidad que se modela en la Fase 1 (aplanada a tabla):** la **imagen**, resumida en rasgos tabulares por hoja (promedios de intensidad por canal R, G, B; un índice de «parduzco»/necrosis; descriptores de textura simples). Con esos rasgos se entrena el MLP de línea base para «enferma sí/no».
- **Paso a la Fase 2:** ese aplanamiento se reemplaza por la **CNN nativa** sobre la imagen cruda, y se **incorpora la rama temporal** con una **RNN/LSTM/GRU** sobre la serie climática; ambas se **fusionan** en una sola predicción.

- **Clave de alineación (se marca una):**
- [x] **Agregada**, **(región, mes)**, con su salvedad de fuga de datos y de rasgo casi constante: las imágenes se recolectaron en las regiones de **Mbeya, Iringa, Njombe y Songwe** (Tierras Altas del Sur de Tanzania) entre **2022-11-22 y 2023-04-08**; la serie de NASA POWER se consulta para esas coordenadas y ese periodo. **Salvedad:** una foto de hoja **no tiene su propio registro climático individual** (solo se conoce la región y la ventana de recolección a nivel del conjunto), y el clima es **casi constante** dentro de una misma (región, mes); por eso la alineación es agregada, no muestra a muestra.
- [ ] Por muestra, p. ej., (finca, semana).
- **Prueba de acoplamiento (obligatoria):** diez filas reales en el **Anexo A** (se producen ejecutando la consulta a NASA POWER indicada; los valores climáticos se llenan al correrla, no se inventan).
- **Si la modalidad aplanada es una serie temporal:** no aplica en la Fase 1 (se aplana la imagen). Cuando la serie entre en la Fase 2, su partición será **cronológica** y los rezagos y transformaciones se calcularán sin mirar el futuro.

6. Línea base comprometida

- **Clase mayoritaria:** la clase mayoritaria es **«enferma»** (38.271 / 58.709 ≈ **65,2 %**; «sana» ≈ 34,8 %). La línea base de clase mayoritaria da una exactitud ≈ **0,652**; como la clase de riesgo («enferma») es la mayoritaria, predecir todo-enferma da *recall*(enferma)=1,0 de forma trivial, así que el modelo se juzga por el *recall* y la precisión de **ambas** clases (en especial no hundir el *recall* de «sana»). Se reportan métricas por clase en el conjunto de prueba.
- **Escalar crudo** (la modalidad aplanada resume rasgos escalares): se reporta el desempeño de **un único rasgo crudo** —p. ej., un índice de necrosis/«parduzco» promedio de la hoja— usado solo, con el umbral elegido en validación. El MLP debe superarlo.
- La partición, la semilla y estas cifras se conservan: son el punto de comparación de las fases siguientes.

7. Riesgos éticos y protección de datos

Riesgo	Daño para el cliente	Mitigación
Sesgo de muestreo o representatividad	El conjunto es de **una variedad (Shangi) y una sola región** (Tanzania); el modelo puede no transferir a variedades y condiciones de otra zona (p. ej., Cundinamarca), dando falsas seguridades.	Declarar el límite de transferencia; aumentar datos (rotación, iluminación, fondos); validar en un subconjunto separado por región; recomendar recalibración antes de usarlo en otra zona.
Falsa alarma (predecir tizón donde no lo hay)	Fumigación innecesaria: costo económico y ambiental, resistencia del patógeno.	Umbral de decisión calibrado en validación según el costo relativo de los errores; reportar la tasa de falsos positivos.
Alarma omitida (no detectar un brote real)	Pérdida de cultivo por intervención tardía.	Priorizar el *recall* de la clase «enferma»; elegir el umbral penalizando los falsos negativos; combinar con la señal climática en la fusión.

El checklist de protección de datos va en el **Anexo C**, uno por fuente.

8. Cita APA 7 de cada fuente

- Laizer, H., Mduma, N., Machuve, D., Lyimo, T., Babirye, C., Swai, J., & Siwingwa, A. (2023). *Irish Potato Imagery Dataset for Early Detection of Crop Diseases* (Versión 01) [Conjunto de datos]. Zenodo. https://doi.org/10.5281/zenodo.8286529
- Laizer, H., & Mduma, N. (2025). Irish potato imagery dataset for detection of early and late blight diseases. *Data in Brief, 60*, 111549. https://doi.org/10.1016/j.dib.2025.111549
- NASA. (s. f.). *POWER | Prediction Of Worldwide Energy Resources* [Conjunto de datos]. NASA Langley Research Center. https://power.larc.nasa.gov/

Anexo A - Prueba de acoplamiento

Clave: **(región, mes)** — región ∈ {Mbeya, Iringa, Njombe, Songwe}; mes ∈ {2022-11 … 2023-04}.

Cada fila une un dato de la rama de imagen (nº de imágenes de ese bloque de recolección, o una imagen de muestra) con el clima de NASA POWER para esa región y mes. **Los valores de la serie se llenan ejecutando la consulta de abajo** (no se inventan).

N.º	Clave (región, mes)	Dato de la rama de imagen (archivo o rasgo)	Dato de la serie (variable y valor)
1	Mbeya, 2022-11	*(p. ej., lateblt/IMG_xxxx.jpg)*	RH2M = *(…)* %, T2M = *(…)* °C
2	Mbeya, 2022-12		RH2M = *(…)*, T2M = *(…)*
3	Mbeya, 2023-01		
4	Iringa, 2022-12		
5	Iringa, 2023-01		
6	Iringa, 2023-02		
7	Njombe, 2023-01		
8	Njombe, 2023-02		
9	Songwe, 2023-02		
10	Songwe, 2023-03		

Código o consulta que produjo las filas (rama temporal, NASA POWER; se ajustan lat/lon por región):

```
import requests, pandas as pd

# Coordenadas aproximadas por región (Tierras Altas del Sur de Tanzania)
regiones = {
    "Mbeya":  (-8.90, 33.46),
    "Iringa": (-7.77, 35.69),
    "Njombe": (-9.34, 34.77),
```

```
    "Songwe": (-9.00, 33.00),
}
params = "T2M,RH2M,PRECTOTCORR"
filas = []
for region, (lat, lon) in regiones.items():
    url = ("https://power.larc.nasa.gov/api/temporal/monthly/point"
           f"?parameters={params}&community=AG&latitude={lat}&longitude={lon}"
           "&start=2022&end=2023&format=JSON")
    r = requests.get(url, timeout=60).json()
    p = r["properties"]["parameter"]
    for ym in ["202211","202212","202301","202302","202303","202304"]:
        filas.append({
            "region": region, "mes": ym,
            "T2M": p["T2M"].get(ym), "RH2M": p["RH2M"].get(ym),
            "PRECTOTCORR": p["PRECTOTCORR"].get(ym),
        })
print(pd.DataFrame(filas))   # se toman 10 filas reales para el anexo
```

Anexo B - Evidencias del test de procedencia

1. **Cadena de procedencia** (un archivo por fila):

Archivo (nombre exacto)	URL o DOI del productor primario	Fecha de descarga	Huella SHA-256
healthy.zip	https://doi.org/10.5281/zenodo.8286529	*(AAAA-MM-DD)*	*(correr hashlib)*
earlyblt.zip	https://doi.org/10.5281/zenodo.8286529	*(AAAA-MM-DD)*	*(correr hashlib)*
lateblt.zip	https://doi.org/10.5281/zenodo.8286529	*(AAAA-MM-DD)*	*(correr hashlib)*

Código de la huella: `hashlib.sha256(open(ruta, "rb").read()).hexdigest()`

2. **Descarga trazable:** la celda de carga descarga los tres .zip desde el DOI de Zenodo (o una copia con la misma huella). Búsqueda en el cuaderno: `grep -inE "kaggle|kagglehub|/kaggle/input" *.ipynb` → sin coincidencias.
3. **Búsqueda declarada de espejos** (fecha 2026-10-30): se buscó «Irish Potato Imagery Dataset» y los nombres de archivo en kaggle.com/datasets. Coincidencias a declarar tras la búsqueda del estudiante; el espejo conocido es **Hugging Face** `Project-AgML/potato_leaf_blight`, con el **mismo origen Zenodo** (no es un origen Kaggle). El corpus PlantVillage de papa (muy presente en Kaggle) es **distinto** (imágenes de laboratorio, fondo controlado): se contrasta en el punto 5.
4. **Huella de crudeza** (antes de limpiar): filas × columnas = **58.709 imágenes** en 3 clases - faltantes: a reportar tras cargar - balance de la etiqueta = sana 20.438 / *early* 17.772 / *late* 20.499 (≈ 35 % / 30 % / 35 %), binario 34,8 % sana / 65,2 % enferma.
5. **Contraste con el espejo** (PlantVillage papa): huella SHA-256 distinta, imágenes de campo (no de laboratorio), fondos y conteos distintos, columnas/estructura originales de Zenodo. Se adjunta una imagen de muestra de cada fuente para evidenciar la diferencia.

Anexo C - Checklist de protección de datos personales (una copia por fuente)

Fuente: Irish Potato Imagery Dataset (Zenodo 8286529)

Regla de la Fase 1: sin personas identificables. Solo se usan datos públicos, agregados o anonimizados por la fuente oficial. «Ley» = Ley 1581 de 2012; «DUR» = Decreto 1074 de 2015.

Resultado (se marca uno): - [x] Sin datos de personas. - [ ] Datos de personas anonimizados por la fuente. - [ ] Datos personales o sensibles → no admisibles en la Fase 1.

A. ¿Hay datos personales? (Ley, art. 3 lit. c)

- [x] Se revisaron columnas, imágenes y metadatos: el contenido son hojas de papa, sin identificadores directos (nombre, documento, rostro, etc.).
- [x] Identificadores indirectos: **riesgo de EXIF/GPS** en fotos de smartphone → se **borran los metadatos EXIF/GPS** antes de cualquier carga a Colab/Drive, y la ubicación se mantiene a nivel de región.
- [x] No hay identificadores seudonimizados.

B. ¿Hay datos sensibles? (Ley, art. 5)

- [x] No hay datos de salud humana, biométricos ni sensibles: es fitosanidad vegetal.

C. ¿Hay niños, niñas o adolescentes? (Ley, art. 7)

- [x] No aplica: no hay personas.

D. Base legal o autorización para datos de terceros

- [x] Fuente pública oficial (Zenodo, con DOI y licencia citable); se citan sus términos de uso una vez confirmada la licencia.

E. Finalidad (Ley, art. 4 lit. b)

- [x] «Uso académico para entrenar y evaluar un modelo en el curso; no se toman decisiones sobre personas identificadas».

F. Anonimización y riesgo de reidentificación

- [x] No hay identificadores directos; se borran los EXIF/GPS de las imágenes.
- [x] Prueba de reidentificación: no es posible identificar a una persona con hojas de papa.

G. Licencia de uso (verificada en la fuente primaria)

- [ ] **Pendiente:** anotar nombre y versión de la licencia leída en la ficha de Zenodo del DOI, con el enlace, y las obligaciones (atribución, etc.).

H. Transferencia internacional (Colab, Drive, GitHub, asistentes de IA)

- [x] A Colab/Drive/GitHub solo se suben datos sin personas identificables (hojas de papa).
- [x] A los asistentes de IA no se les pegan registros reales de personas (no los hay).

I. Minimización y conservación

- [x] Solo se conservan las imágenes y columnas necesarias; se declara dónde se guardan los crudos y que se borran al terminar la Fase 3.

J. Publicación del repositorio (Ley, art. 4 lit. f)

- [x] El repositorio es privado y compartido con el docente, o público con un script que descarga desde Zenodo (datos en `.gitignore` si la licencia no permite redistribuir); las salidas no muestran datos personales.

Fuente: NASA POWER — Resultado: **Sin datos de personas** (datos meteorológicos agregados por celda geográfica). Licencia: datos NASA de libre uso, con la atribución indicada. Transferencia internacional: solo datos ambientales, sin personas. Las demás casillas (A–J) se marcan «no aplica / sin personas».

Declaración. Lo consignado en este checklist es verdadero y se revisó para cada fuente de la Propuesta.

Integrante	Firma	Fecha (AAAA-MM-DD)
Juan Guillermo Montaño Junca		2026-10-30
Jair Andrés Valderrama Cano		2026-10-30